

S - input size; B - batch size

$Flops(S, B)$ - число операций с mem. точкой

$Memory(S, B)$ - max mem.

$Latency(S, B)$ - время 1 Forward

$Energy(S, B, \theta)$ - energy joule

θ - параметры конкретной змк (все еще не известно)

Ex Дз 1
 25 сентября 2026 г. $S=2$ (stride) $p=3$ (padding)

1. доступный размер $= S + 2p$
2. Если k можно поделить в позиции $0, S, 2S, \dots$
3. Число позиций $= \left\lfloor \frac{S + 2p - k}{S} \right\rfloor + 1$ $2 + 2p - k$ - последний доступный

$$\frac{S + 6 - 1}{2} = \frac{S}{2} + \frac{1}{2} + 1 = \frac{S}{2} + \frac{1}{2}$$

$$flops = \left(\frac{S}{2} + \frac{1}{2}\right)^2 \cdot B \cdot Const, \text{ по } S - \text{сетью} \Rightarrow \left(\frac{S}{2}\right)^2 \cdot B \cdot C$$

Т.к. $S \times S$ изобраз.

каждое число - полученное из операции

$$\Rightarrow K \cdot K \cdot C_{in} \cdot \text{высота} \cdot \text{глубина батча и Const}$$

то $Flops$ для 1 прохода операции | P.S. отнимите свои
 в код пока проходите

Memory - ищем момент, когда определено имеет больше всего данных

$$Memory(S, B) = M_{model} + 4 \left[\underbrace{B \cdot 32 \cdot S^2}_{\text{вход FP32}} + \underbrace{B \cdot 32 \cdot (S/2)^2}_{\text{вход conv}} + \underbrace{B \cdot 32 \cdot (S/2)^2}_{\text{вход BatchNorm}} \right]$$

$x = \dots device = "cuda")$

Latency: 2. Нужно вычислить Формулы (формулы)

P - скорость операции в секунду

1. L - время при старте

3. При времени прочитать и записать $Q(S, B)$ байт. Если эффективная пропускная способность W байт в секунду $\Rightarrow Q/W$

Предположим, что вы не знаете и обмен с памятью и/или чтение в эту формулу

$$Latency(S, B, \theta) = L + \max\left(\frac{F(S, B)}{P}, \frac{Q(S, B)}{W}\right)$$

Как посчитать Q - ?

Для одного блока: $Conv \rightarrow BatchNorm \rightarrow ReLU$

A_{in} - входной тензор

A_{out} - выходной

$K = C_{in} \times C_{out} \times K^2$ - число весов; C - каналы

$Conv - A_{in} + K \rightarrow A_{out}$

$BatchNorm - A_{out} \text{ и } C_{out} \text{ conv параметров, } A_{out}$

$ReLU - A_{out}$ A_{out} - те же элементы

$$B_{block} = 4 \cdot (A_{in} + K + 5A_{out} + 4C_{out})$$

и байты FP32

Куда модель, но все же (комментарий)

$Energy(S, B, \theta)$ - мощность на время

$$E_{base} = P_{idle} \cdot Latency(S, B) \cdot pred$$

базовая мощность змк

$$E(S, B) = P_{idle} \cdot T(S, B) + E_{fixed} + a_F \cdot \frac{F(S, B)}{10^9} + a_Q \cdot \frac{Q(S, B)}{10^9}$$

мощность в простое

T - пропускная Latency F - формулы Q - перемещение байт

a_F и a_Q - пропуск на billion operati

Откуда мы берем E_{fixed} a_F и a_Q

Lit-energy():

$$y_i = E_i^{means} - P_{idle} T_i^{pred} \quad \{S_i, B_i\}_{i=1}^n$$

$$E_i^{means} = \frac{P_{idle} \cdot T_i^{pred} + E_{fixed} + a_F F_i + a_Q Q_i}{N}$$

$$\hat{y}_i = E_{fixed} + a_F \frac{F_i}{10^9} + a_Q \frac{Q_i}{10^9}$$

$$\text{minimize} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{d_i} \quad d_i - \text{весовый} = \max(E_i^{means}, 5 - \text{и нежелательные значения энергии отклонение от 0})$$

коэффици. по факту и/или минимизируем

для Latency подберем L P и W - они у нас
 и зависят от θ

$$a = \frac{10^9}{P} \quad c = \frac{10^9}{W} \quad f_i = \frac{F_i}{10^9}; \quad q_i = \frac{Q_i}{10^9}$$

$$L_i = L + \max(a f_i, c q_i) = L + \max\left(\frac{F_i}{P_i}, \frac{Q_i}{W_i}\right)$$

$$(L^*, a^*, c^*) \in \argmin_{L, a, c \geq 0} \sum_{i \in \text{train}} \left[\frac{L + \max(a f_i, c q_i) - T_i^{means}}{d_i} \right]^2$$

линейно по факту

One note
 Sample
 замеч
 сформулировано