Дз1 в2

27 сентября 2026 г. 17:13

1. Обозначения и размеры тензоров

S - сторона квадрата image B - batch

Усл: $S \geq 32$ кратно 16 $B \geq 0$

$X = BS^2$

Input: $(B, 3, S, S)$ - 3X чисел; FP32 - 4 байта

1MiB = 2^{20} bytes

k - размер ядра; p - паддинг, h - высота (ширина) входа слоя, s - страйд

∀ Conv bias = False: dilation = 1;

BatchNorm и Relu inplace = True

cudnn.benchmark = False; allow_tf32 = false

Для входной h, ядра k, p и s:

$$h_{out} = \left\lfloor \frac{h+2p-k}{s} \right\rfloor + 1$$

Для Conv1: $\left\lfloor \frac{S+6-7}{2} \right\rfloor + 1 = \frac{S}{2}$ S четное

MaxPool далее даёт $\frac{S}{4}$, следующие stride-2 Conv $\frac{S}{8}$ $\frac{S}{16}$

2. Flops: от одного выходного числа ко всем свёрткам.

Для 1 выходного числа Conv используется $C_{in}k^2$

MAC = 2 Flops => $2C_{in}k^2$ - для 1

$$F_{conv} = 2\underbrace{BC_{out}h_{out}^2}_{\text{всего выходных чисел}} \cdot C_{in}k^2$$

3. Flops: BatchNorm, pooling, head и итого:

В eval BN использует сохр. μ σ^2

$$y = \gamma \frac{x-\mu}{\sqrt{\sigma^2+\varepsilon}} + \beta = ax + b$$ => 1 умн + 1 сложение

=> $F_{BN} = 2N_{out}$. Подготовку a, b и реализации kernel не учитываем.

Напишите, если нужно было учитывать, плиз

ReLu и Maxpool проводят сравнения. Т.к. мы используем только MAC, то их тоже опускаем из расчетов

Global Avg Pooling: в 1 C $n = \left(\frac{S}{16}\right)^2$ чисел (после Conv6)

=> n-1 сложение и 1 деление. Каналов 512 и всего:

=> $F_{GAP} = 512B\left(\frac{S}{16}\right)^2 = 2X$

Flatten - не выполняет арифметику

Linear 1. для каждого из 256 выходов - 512 MAC + bias

$FL_1 = B(2\cdot512\cdot256+256) = 262400B$

Linear 2.

$FL_2 = B(2\cdot256\cdot100+100) = 51300B$

Total:

$$F(S,B) = F_{conv\,total} + F_{BN\,total} + F_{GAP} + F_{L_1} + F_{L_2}$$

4. Память:

$$M(S,B) = \underbrace{W_{alloc}}_{\text{модель}} + \underbrace{W_{BLAS}}_{\text{workspace}} + \underbrace{M_{active}}_{\text{живые активации}}$$

Walloc:

∀ Conv + BN + ReLU:

$$W_i = \underbrace{r(4C_{in}C_{out}k^2)}_{\text{веса Conv}} + \underbrace{4r(4C_{out})}_{\text{4 вектора BN}} + \underbrace{r(8)}_{\text{счетчик 1 int64}}$$

$r(n) = \left\lceil \frac{n}{512} \right\rceil 512$ — в модели native cuda Allocator запрос отдельного тензора

Linear хранит: $r(4N_{in}N_{out}) + r(4N_{out})$

=> $W_{alloc} = \sum_{i=1}^{6} W_i + W_{L_1} + W_{L_2}$

W_{BLAS}: рабочая память в BLAS (T4, Pytorch 2.11)

после прогрева учитывали постоянный workspace в Blas

$W_{BLAS} = (2\cdot4096 + 8\cdot16)\cdot1024$ (1 cuda stream)

Mactive:

$A_{peak}(S,B) = \max_t A_{live}(t)$

$A_{input} = 4\cdot B\cdot 3S^2 = 12BS^2$

$A_{conv1} = 4\cdot B\cdot 32\left(\frac{S}{2}\right)^2 = 4\cdot B\cdot 32\frac{S^2}{4} = 32BS^2$

BatchNorm создаёт новый тензор той же формы

=> $A_{live,BN1} = A_{input} + A_{conv1} + A_{BN1,out} = 76BS^2$ байт

Я не буду рисовать таблицу, но на последующих шагах у нас идёт падение + их активная память меняется + Relu inplace

=> $A_{peak}(S,B) = 76BS^2$

5. Latency

$$T(S,B) = \underbrace{t_0}_{\text{время запуска вычислений}} + \max\left(\frac{F(S,B)}{P(B)}, \frac{Q(S,B)}{R}\right)$$

P(B) - эффективная скорость выч. Flops/c

$$P(B) = \begin{cases} P_1, & B \leq 64 \\ P_2, & B > 64 \end{cases}$$

Q / R - время обмена данными

Q - объем чтения и записи

t_0, P_1, P_2, R и порог B - определяем по train (θ)

Q одного блока Conv → BN - Relu:

$$\left.\begin{aligned} A_{in} &= BC_{in}H_{in}W_{in} \\ A_{out} &= BC_{out}H_{out}W_{out} \\ K &= C_{in}C_{out}k^2 \end{aligned}\right\} \text{числа}$$

$q_{conv} = A_{in} + K + A_{out}$

$q_{BN} = 2A_{out} + 4C_{out}$

$q_{Relu} = 2A_{out}$ — далее inplace читает и записывает

$Q_{block} = 4(A_{in} + 5A_{out} + K + 4C_{out})$

Maxpool $q = 8X + 2X = 10X$

$q_{GAP} = 2X + 512B$

flatten - skip

$q_{Relu,head} = 256B + 256B = 512B$

$q_{L_2} = 256B + 256\cdot100 + 100B = 356B + 256000$

R: подбираем с остальными параметрами

$$\hat{T}_i = t_0 + \max\left(\frac{F_i}{P(B_i)}; \frac{Q_i}{R}\right)$$

$f_i = \frac{F_i}{10^9}$, $q_i = \frac{Q_i}{10^9}$; $a = \frac{10^9}{P_1}$; $c = \frac{10^9}{R}$; $d = \frac{10^9}{P_2} - \frac{10^9}{P_1}$

B_* - выбранный порог

$$\hat{T}_i = t_0 + \max\left(f_i(a + d\,1_{B_i > B_*}), c q_i\right)$$

1 - индикатор большого батча

$t_0, a, c, d \geq 0$

non linear least squares TRF → $\min_{t_0,a,c,d\geq0} \sum_{i\in train} \left(\frac{\hat{T} - T_i^{means}}{s_i}\right)^2$

$s_i = \max\left(T_i^{means}, 0.05\, median_{j\in train}\, T_j^{means}\right)$

6. Energy:

E(S,B) - сколько joules на 1 forward Batch

$$E(S,B) = (P_{idle} + P_{active})\cdot T(S,B) + e_0 + e_F\frac{F(S,B)}{10^9} + e_Q\frac{Q(S,B)}{10^9}$$

База: $E = P\cdot T$ или $E = \int_0^T P(t)\,dt$

Приближение:

Emeans: $\frac{\overline{P_{GPU}}\,\Delta t}{N}$

$\overline{P_{GPU}}$ - средняя мощ.

Δt - длит. серии

N - к-во forward

P_{idle} - мощность простоя через NVML

=> $E_{idle} = P_{idle}\cdot T(S,B)$

P_{active} - подбираем с остальными на train

Остальные:

e_0 - постоянный расход за 1 forward Дж

$e_F\cdot F/10^9$ - расход связанный с операциями. Дж/GFlops

$e_Q\, Q/10^9$ - // - передача данных Дж/GB

Fit:

$y_i = E_i^{means} - P_{idle}\hat{T}_i$

$\hat{y}_i = e_0 + e_F\frac{F_i}{10^9} + e_Q\frac{Q}{10^9} + P_{active}\hat{T}_i$

$$\min_{e_0,e_F,e_Q,P_{active}\geq0} \sum_{i\in train}\left(\frac{\hat{y}_i - y_i}{u_i}\right)^2$$

$u_i = \max\left(E_i^{means}, 0.05\, quantile_{10,train}\, E_i^{means}\right)$

NNLS